

Projekt

Autor: Karolina Gralak

Numer indeksu: 333051

1 Wstęp

Celem projektu było zbudowanie modelu klasyfikacyjnego przewidującego prawdopodobieństwo przynależności obserwacji do jednej z klas na podstawie zbioru cech numerycznych.

W projekcie początkowo porównano kilka klasycznych modeli uczenia maszynowego, a następnie wykorzystano metody ensemble- voting oraz stacking, w celu poprawy jakości predykcji.

2 Opis danych i wstępna analiza

Zbiór danych składa się z obserwacji opisanych przez 100 cech numerycznych. Zmienna celu ma charakter binarny (klasa 1 oraz klasa 2). W ramach wstępnej eksploracji danych sprawdzono:

- obecność braków danych,
- typy zmiennych,
- rozkłady cech,
- proporcje klas zmiennej celu.

Nie stwierdzono braków danych, dlatego nie było konieczne stosowanie imputacji. Wszystkie cechy miały charakter numeryczny. Ze względu na dużą liczbę zmiennych zastosowano metody selekcji oparte na modelach.

Jako główną miarę jakości modelu wybrano **balanced accuracy** wyrażoną wzorem:

$$BA = \frac{1}{2} \left(\frac{TP}{P} + \frac{TN}{N} \right)$$

.

3 Przygotowanie danych

Aby uniknąć problemów związanych z różnymi skalami zmiennych zastosowano standaryzację danych przy użyciu `StandardScaler`. Dodatkowo usunięto cechy o bardzo niskiej wariancji przy użyciu `VarianceThreshold`.

Kluczowym elementem preprocessingu była selekcja cech. Zastosowano metodę `SelectFromModel`, w której jako estymator wykorzystywano różne modele uczenia maszynowego. W ramach

strojenia hiperparametrów porównano selekcję opartą na `RandomForestClassifier` oraz na regresji logistycznej z regularizacją L1. Wybór optymalnego selektora oraz jego parametrów był dokonywany automatycznie w procesie walidacji krzyżowej, na podstawie wartości metryki *balanced accuracy*. Wszystkie etapy preprocessingu zostały umieszczone w obiektach typu `Pipeline`, co zapobiega wyciekowi informacji (data leakage) podczas walidacji krzyżowej.

4 Modele bazowe

Na początku nastrojono kilka modeli bazowych, które następnie posłużyły jako komponenty metod ensemble. Rozważono następujące algorytmy:

1. regresję logistyczną
2. las losowy (Random Forest),
3. k-najbliższych sąsiadów (kNN),
4. model wektorów podpierających.

Dla każdego modelu zbudowano osobny pipeline zawierający standaryzację, selekcję cech oraz model końcowy. Parametry modeli były dobierane przy użyciu `GridSearchCV` z wykorzystaniem 5-krotnej walidacji krzyżowej typu `StratifiedKFold`. Po zakończeniu strojenia wybrano najlepszą konfigurację każdego modelu na podstawie średniej *balanced accuracy*. Dodatkowo za pomocą kroswalidacji wybrano, który model lepiej wybiera cechy. Lepszy okazał się `RandomForestClassifier`.

Wyniki strojenia (wartości wybranych hiperparametrów dla poszczególnych modeli) prezentują się następująco:

1. Regresja logistyczna: $C=10$
2. Las losowy: $n_estimators = 100$, $min_samples_leaf=1$, $max_features=0.5$, $max_depth = 15$,
3. k-najbliższych sąsiadów (kNN): $n_neighbors=10$, $weights='distance'$,
4. Model wektorów podpierających: $C=5$, $gamma = 'scale'$.

5 Metody ensemble

Po nastrojeniu modeli bazowych zastosowano metody ensemble w celu poprawy jakości predykcji.

5.1 Stacking

Aby "połączyć" predykcje modeli bazowych zaczęto od zastosowania `StackingClassifier`. W metodzie tej modele bazowe generują predykcje, które następnie stanowią wejście dla modelu meta (final estimator).

W projekcie zastosowano stacking z następującymi cechami (podejście 1):

- modele bazowe: regresja logistyczna, Random Forest, kNN, SVC,
 - meta-model: regresja logistyczna,
- oraz (podejście 2):
- modele bazowe: regresja logistyczna, Random Forest, kNN, SVC,
 - meta-model: RandomForest,

W obu przypadkach wykorzystano walidację krzyżową, by nastroić hiperparametry dla selectora i meta-modelu. Modele bazowe wykorzystywano w konfiguracjach wybranych na wcześniejszym etapie strojenia.

5.2 Voting

Zastosowano również metodę `VotingClassifier` w trybie `soft`, by porównać wyniki. W tym podejściu prawdopodobieństwa predykcji generowane przez modele bazowe są uśredniane, a następnie na ich podstawie podejmowana jest decyzja klasyfikacyjna. Tryb `soft voting` pozwala uwzględnić stopień pewności poszczególnych modeli.

Wszystkie modele bazowe wykorzystywane w votingu posiadały metodę `predict_proba`, co umożliwiało zastosowanie tego podejścia.

6 Wybór modelu i wnioski

Poniższa tabela przedstawia wartości metryki *balanced accuracy* uzyskane w walidacji krzyżowej dla poszczególnych modeli.

Model	Balanced Accuracy
Stacking z regresją	0.892
Stacking z lasem	0.891
Voting	0.889
Random Forest	0.884
kNN	0.883
SVC	0.854
Regresja logistyczna	0.611

Jak widać, wartości metryki *balanced accuracy* dla większości rozważanych modeli (oprócz regresji logistycznej) są do siebie zbliżone. Może to wskazywać, że dostępne cechy zawierają wystarczającą ilość informacji do rozróżniania klas, a dalsze zwiększanie złożoności modeli prowadzi jedynie do umiarkowanej poprawy jakości predykcji.

Jako model końcowy wybrano konfigurację `stackingu`, która uzyskała najwyższą średnią wartość *balanced accuracy* w walidacji krzyżowej. Takie podejście pozwala połączyć zalety różnych algorytmów uczenia maszynowego oraz zwiększyć stabilność i odporność modelu na błędy pojedynczych klasyfikatorów.

Wybrany model został dopasowany do zbioru treningowego i użyty do wygenerowania wektora prawdopodobieństw przynależności do klasy 1 dla danych testowych.